



RAG(Retrieval-Augmented Generation)

Contents

R.A.G. 개념 및 활용

01. R.A.G. 의 개념

02. Vector DB 의 개념과 활용

03. Local LLM 활용(Ollama)

01.

RAG 개념

RAG 개념

- 우리가 시험을 본다고 가정했을 때 걱정되는 부분을 생각해 보자
 - 내가 정확하게 알고 있는 게 맞을까?
 - 시험을 보기 전까지 새로운 유형의 문제가 생기지 않았을까?
 - 시험 범위 밖에서 출제되진 않았을까?

문제	설명
환각	AI 가 모르는 내용도 아는 것처럼 지어냄
정보의 유통기한	AI 의 학습은 실시간이 아님(특정시점 까지의 데이터로만 학습)
보안 및 폐쇄성	보안이 중요한 문서나 내용에 대해서는 학습이 불가능

RAG 개념

- 만약 보는 시험이 오픈 북 시험이라면?
 - 정확도와 최신성, 신뢰성이 향상된다.

단계	설명
질문(Query)	사용자가 "우리 회사 이번 달 복지 혜택이 뭐야?"라고 묻는다.
검색(Retrieval)	회사의 최신 복지 규정 PDF 문서에서 질문과 가장 관련 있는 내용을 찾아낸다.
증강 (Augmentation)	찾아낸 문서 내용과 사용자의 질문을 합친다. "이 문서 내용을 바탕으로 질문에 답해줘: [복지 규정 내용.pdf]"
생성(Generation)	AI가 전달받은 근거 문서를 읽고 정확한 답변을 생성

Summary

- ☑ 기존 AI 는 환각, 정보의 유통기한, 보안 및 폐쇄성 등의 문제가 있었다.
- ☑ RAG 를 활용하면 이런 문제들을 상당수 해소 할 수 있다.
- ☑ RAG 는 검색(Retrieval), 증강(Augmentation), 생성(Generation) 순으로 답변을 생성

02.

Vector DB 의 개념과 활용

Vector DB 의 개념

- 기존의 DB 는 키워드의 양과 정확도로 데이터를 찾는다.
- Vector DB 는 데이터의 의미를 숫자로 변환하여 저장하고 찾는다.
- '강아지' 를 검색 했을 때 유사도 높은 기존의 문서를 찾는 기준을 보자

1. 강아지
2. 강어지
3. 갱애지

← 기존 DB : 일치하는 글자수에 따라 유사도를 판정

1. 강아지
2. 멍멍이
3. 땡땡이

← Vector DB : 좌표 근접성에 따라 유사도를 판정

- 벡터화(Embedding): 텍스트, 이미지, 오디오 같은 데이터를 숫자 배열(좌표)로 만드는 과정

Vector DB 의 개념

- 벡터 DB는 문장의 의미적 유사성을 파악하고 저장한다.
- 때문에 **반려견** 건강 관리법 을 물었을 때, **개** 키울 때 주의점 이라는 문서도 함께 찾아낸다.



- 우리가 사용할 벡터 DB 의 종류에 대해서 알아보자

유형	종류	특징
전용벡터 DB	chroma , milvus, weaviate, pinecone	성능과 기능이 가장 강력함
확장형 DB	pgvector, Elasticsearch	기존 DB에 벡터 검색 기능을 추가한 형태
경량/로컬 DB	FAISS, LanceDB	서버 없이 메모리에서 빠르게 돌릴 수 있음

Chroma 설치 및 실행

Chromadb 설치 및 실행

- Chromadb 는 Python 라이브러리로써 복잡한 설치 없이 실행 가능 하다.

```
pip install chromadb
```

```
import chromadb

client = chromadb.PersistentClient(path="./my_db")
collection = client.get_or_create_collection(name="my_collection")
collection.add(
    documents=[
        "RAG는 외부 데이터를 참조하여 답변을 생성하는 기술입니다.",
        "벡터 DB는 의미적 유사도를 바탕으로 데이터를 검색합니다.",
        "파이썬은 데이터 과학과 AI 분야에서 널리 쓰이는 언어입니다."
    ], ids=["id1", "id2", "id3"] # 각 데이터의 고유 ID
)
results = collection.query(query_texts=["RAG가 무엇인가요?"], n_results=2)
print(f"검색 결과: {results}")
```

실습파일 : 01_start.py

Chromadb 사용법

Chromadb 의 CRUD

- Chromadb 도 DB 인만큼 기본적인 CRUD 가 가능 하다.

태그이름	설명
add()	데이터 추가
get()	정확한 ID나 메타데이터 조건(where)에 일치하는 데이터를 가져옴(전통적 DB 방식)
query()	질문의 '의미'가 유사한 데이터를 가져옴(벡터 DB의 핵심 기능)
update()	해당 ID의 데이터를 수정
upsert()	ID가 있으면 update() , 없으면 add() 를 수행
delete()	특정 ID만 지우거나, 특정 카테고리의 모든 데이터를 한꺼번에 지움

실습파일 : 02_crud.py

Chromadb 사용법

✓ metadata

- Metadata 는 검색의 효율을 높이는 filter 역할을 수행
- Vector DB 의 의미 검색에 정확도를 추가해 줄 수 있다.

```
collection.add(  
    documents=["파이썬 기초 문법 가이드", "자바 고급 성능 최적화"],  
    metadatas=[  
        {"lang": "python", "level": "beginner", "version": 3.12},  
        {"lang": "java", "level": "advanced", "version": 21}  
    ],  
    ids=["doc1", "doc2"]  
)
```

```
results = collection.query(  
    query_texts=["공부할 내용을 추천해줘"], n_results=1,  
    where={  
        "$and": [  
            {"lang": {"$eq": "python"}},  
            {"level": {"$eq": "beginner"}}  
        ]  
    }  
)
```

Chromadb 사용법

조건 검색(where)

- where 는 메타데이터 값을 대상으로 조건을 걸어 문서를 필터링 한다.

연산자	의미	예시
\$eq	같다 (Equal)	{"category": {"\$eq": "news"}}
\$ne	같지 않다 (Not Equal)	{"status": {"\$ne": "deleted"}}
\$gt	크다 (Greater Than)	{"price": {"\$gt": 1000}}
\$gte	크거나 같다 (Greater Than or Equal)	{"version": {"\$gte": 2.0}}
\$lt	작다 (Less Than)	{"page": {"\$lt": 10}}
\$in	SQL 의 IN 절과 동일	{"lang": {"\$in": ["py", "js"]}}
\$nin	SQL 의 NOT IN 절과 동일	{"lang": {"\$nin": ["py", "js"]}}

실습파일 : 04_where.py

Summary

- ☑ Vector DB 는 데이터의 의미를 숫자로 변환하여 저장하고 찾는다.
- ☑ 그래서 문장의 의미적 유사성을 숫자(좌표)로써 파악하고 저장한다.
- ☑ 상황에 맞는 Vector DB 를 사용할 수 있다.

유형	종류	특징
전용벡터 DB	chroma , milvus, weaviate, pinecon	성능과 기능이 가장 강력함
확장형 DB	pgvector, Elasticsearch	기존 DB에 벡터 검색 기능을 추가한 형태
경량/로컬 DB	FAISS, LanceDB	서버 없이 메모리에서 빠르게 돌릴 수 있음

03.

Local LLM 활용(Ollama)

Local LLM 활용

- 이전에는 chromaDB 의 임베딩 모델(all-MiniLM-L6-v2)을 사용했다.
- 이 외에도 외부 API 를 사용 할 수 있지만 여러 문제에 직면하게 된다.
- 그래서 Local LLM 을 사용하기도 한다.

구분	Gemini API	Local LLM(Ollama + Gemma)
장소	구글 서버(Cloud Server)	내 컴퓨터(Local)
필요자원	인터넷	고 사양 GPU/RAM
설정 난이도	매우 쉬움(google API KEY 만 있으면 가능)	보통(ollama 설치 필요)
보안	데이터가 구글로 전송됨	데이터가 Local 밖으로 나가지 않음
토큰	다 사용하면 더 이상 사용 불가	제한 없음
트래픽 부하	복잡한 분석 요구시 503(서버 과부하) 오류 발생	컴퓨터가 느려짐(사양에 따라서 다름)

Gemini API 를 원한다면

chroma db 에서 gemini api 를 이용해 임베딩하여 데이터를 입력하고 검색하는 예제 만들어줘, API 키는 소스 안에 서 설정하고 싶어

Local LLM 활용

- 먼저 ollama(<https://ollama.com/>) 를 설치 해 주자
- Power shell 실행 후 아래 명령어를 넣어서 다운로드 및 설치가 가능하다.



Power OpenClaw with Ollama

The easiest way to build
with open models

```
irm https://ollama.com/install.ps1 | iex
```


paste this in PowerShell, or [download Ollama](#)

```
irm https://ollama.com/install.ps1 | iex
```

```
(.venv) PS D:\local_llm> irm https://ollama.com/install.ps1 | iex
>>> Downloading Ollama for Windows...
##### 100.0%
>>> Installing Ollama...
>>> Install complete. Run 'ollama' from the command line.
```

Local LLM 활용

- Ollama 를 실행해 보자
- Ollama 는 로컬환경에서 LLM 을 실행 할 수 있는 **실행도구** 이다.
- 그래서 **실행할 Local LLM 을 설치** 하여 사용해야 한다.
- <https://ollama.com/library>



Models

Docs

Pricing

gemma4

Gemma 4 models are designed to deliver frontier-level performance at each size. They are well-suited for reasoning, agentic workflows, coding, and multimodal understanding.

vision tools thinking audio cloud e2b e4b 26b 31b

↓ 6M Pulls 29 Tags Updated 1 week ago

laguna-xs.2

Laguna XS.2 is a 33B total parameter Mixture-of-Experts model with 3B activated parameters per token designed for agentic coding and long-horizon work on a local machine.

tools thinking

↓ 705 Pulls 7 Tags Updated yesterday

qwen3.5

Qwen 3.5 is a family of open-source multimodal models that delivers exceptional utility and performance.

vision tools thinking cloud 0.8b 2b 4b 9b 27b 35b 122b

↓ 7.4M Pulls 58 Tags Updated 3 weeks ago

Local LLM 활용

- GPU 와 RAM 이 충분치 않다면 exaone3.5:2.4b 버전을 설치하자
- Exaone 은 LG AI연구원에서 개발하고 오픈소스로 공개한 한국어/영어 대형 언어 모델
- ollama run <model>:<version>
- ollama run hf.co/{사용자명}/{모델저장소명}:latest
- 설치 후 >>> 표시는 LLM 과의 채팅 모드 이므로 /bye 로 빠져나와 주자

```
ollama run exaone3.5:2.4b  
ollama run nomic-embed-text
```



NAME	ID	SIZE	MODIFIED
nomic-embed-text:latest	0a109f422b47	274 MB	6 seconds ago
exaone3.5:2.4b	13644fc3d28e	1.6 GB	57 minutes ago
bge-m3:latest	790764642607	1.2 GB	21 hours ago
exaone3.5:7.8b	c7c4e3d1ca22	4.8 GB	21 hours ago

Local LLM 활용

- Ollama 와 exaone 이 제대로 연동 되었는지 간단한 테스트를 진행해 보자

```
resp = chat(  
    model='exaone3.5:7.8b',  
    messages=[{'role': 'user', 'content': text}]  
)
```

한번에 답변


```
resp = chat(  
    model='exaone3.5:7.8b',  
    messages=[{'role': 'user', 'content': text}],  
    stream=True  
)
```

실시간 답변

실습파일 : local_llm/01_connect.py

Local LLM 활용

- PDF 의 내용을 저장하고 관련 질문에 답을 하는 앱을 만들어 보자




실습파일 : local_llm/02_pdf_store

순서	설명
1	자료를 수집한다.
2	임베딩함수 를 이용하여 벡터화 한다.
3	벡터화 한 자료는 벡터DB 에 저장 된다.

Local LLM 활용

- PDF 의 내용을 저장하고 관련 질문에 답을 하는 앱을 만들어 보자



실습파일 : local_llm/02_pdf_store

순서	설명
1	질의 문을 벡터화 한다
2	벡터 DB 에 질의 한다.
3	질의문과 가져온 내용을 LLM 에게 전달한다.
4	LLM 으로 부터 정보를 받는다.

Local LLM 활용

- 이번엔 수업 교안을 학습시켜 원하는 내용을 찾는 서비스를 만들어 보자
- RTX 3050 / 4050 급 외장 그래픽이 있다면 gemma e4b 나 9b 도 사용 할 수 있다.

```
ollama run gemma4:e2b
```

기능	사용 모델
임베딩	all-MiniLM-L6-v2
토큰나이저	len
질의문 처리	exaone3.5:7.8b

실습파일 : local_llm/03_test

Summary

- ☑ Vector 화에 사용하는 모델에 따라 정확도가 달라진다.
- ☑ 입력 데이터 외에, 질의문도 Vector 화 하면 더 높은 정확도의 답을 얻어 낼 수 있다.
- ☑ Vector DB 의 데이터를 첨부하면 LLM 으로부터 더 좋은 품질의 대답을 얻어 낼 수 있다.
- ☑ Cloud LLM 의 경우 여러 단점이 있기에 Local LLM 을 사용하기도 한다.